

PLANO DE TRABALHO

Análise e desenvolvimento computacional de estudos de propagação de ondas milimétricas em ambientes indoor com superfícies Refletoras Inteligentes (RIS)

Discente: Michelly Luis Lacerda

Orientador: Me. André Almeida Souza Coelho

SUMÁRIO

1. Introdução
2. Atividades propostas
3. Cronograma

PLANO DE TRABALHO

1. Introdução

- As RIS são estruturas de superfícies formadas com elementos radiantes passivos;
- As RIS são uma tecnologia promissora para melhorar a eficiência e a confiabilidade de redes sem fio em ambientes internos e urbanos;
- O presente projeto visa desenvolver estudos e simular computacionalmente o uso de RIS em propagação indoor com ondas milimétricas.

PLANO DE TRABALHO

2. Atividades propostas

1. Pesquisa Bibliográfica
2. Simulação computacional
3. Desenvolvimento de soluções/protótipos
4. Avaliação de cenários (Estudo de Casos) e de Propostas
5. Escrita de Relatório (Semestral)/Artigo

PLANO DE TRABALHO

3. Cronograma

Atividade	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6	Mês 7	Mês 8	Mês 9	Mês 10	Mês 11	Mês 12
1												
2												
3												
4												
5												

RESUMO E ANÁLISE

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

Discente: Michelly Luis Lacerda

Orientador: Me. André Almeida Souza Coelho

SUMÁRIO

1. Introdução
2. Desenvolvimento
3. Resultados
4. Conclusão
5. Considerações finais

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

1. Introdução

- A estimativa de canal para sistemas MIMO é um empecilho intensificado em ambientes indoor devido ao elevado número de reflexões e parâmetros que devem ser analisados;
- Soluções tradicionais para resolução do problema tornam-se mais complexas e computacionalmente mais caras com o aumento do número de dispersores;
- Proposição de um aprendizado de offset baseado em redes neurais;
- A RIS, como um aparelho passivo, não possui radio frequência e isso impede a funcionalidade de sinais pilotos;
- As dispersões mudam rapidamente em cenários industriais para aplicações 5G/B5G.

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

1. Introdução

Objetivo:

- Combinar RIS e aprendizado profundo a fim de aumentar a cobertura da comunicação B5G;
- Explorar novas técnicas de estimação de canal com arquiteturas de aprendizado profundo para estimar os canais assistidos por RIS com uma quantidade reduzida de sobrecarga de piloto em cenários de comunicação indoor.

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

2. Desenvolvimento

- O vetor de sinal transmitido associado à b -ésima subportadora ($1 \leq b \leq B$) pode ser expresso por:

$$\mathbf{x}_b = \mathbf{P}_b \mathbf{s}_b, \quad (1)$$

- Sinal recebido pelo usuário: $\hat{\mathbf{y}}_b = \mathbf{W}_b (\mathbf{H}_{UA,b}^H + \mathbf{G}^H \mathbf{\Theta} \mathbf{H}_{IA}) \mathbf{x}_b + \mathbf{n}_b, \quad (2)$

- Canal AP-RIS: $\mathbf{H}_{IA} = \mathbf{H}_{IA,NLOS} + \mathbf{H}_{IA,LOS}, \quad (3)$

$$\mathbf{H}_{IA,NLOS} = \gamma \sum_{c=1}^C \sum_{s=1}^{S_c} \beta_{c,s} \sqrt{G_e(\theta_{c,s}^{IRS}) L_{c,s}^{IRS}} \mathbf{a}(\varphi_{c,s}^{AP}) \times \mathbf{a}(\phi_{c,s}^{IRS}, \theta_{c,s}^{IRS})^H$$
$$\mathbf{H}_{IA,LOS} = \Gamma(d_{IRS}) \sqrt{G_e(\theta_{LOS}^{IRS}) L_{LOS}^{IRS} \eta} \mathbf{a}(\varphi_{IRS}^{AP}) \mathbf{a}(\phi_{LOS}^{IRS}, \theta_{LOS}^{IRS})^H,$$

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

2. Desenvolvimento

- Canal RIS-UE: $\mathbf{G} = \sqrt{G_e(\theta_{UE}^{IRS}) L_{LOS}^{IRS-R}} e^{j\eta} \mathbf{a}(\phi_{UE}^{IRS}, \theta_{UE}^{IRS}) \mathbf{a}(\varphi_{LOS}^{UE})^H,$
- Canal AP-UE: $\mathbf{H}_{UA,b} = \gamma \sum_{c=1}^C \sum_{s=1}^{S_c} \beta_{c,s} \sqrt{G_e(\theta_{c,s}^{UA}) L_{c,s}^{IRS}} \mathbf{a}(\varphi_{c,s}^{UE}) \mathbf{a}(\phi_{c,s}^{IRS}, \theta_{c,s}^{IRS}),$
- Portanto, o sinal recebido pode ser obtido pela operação de vetorização utilizando a equação 2:

$$\mathbf{y}_b = (\mathbf{P}_b \mathbf{s}_b \otimes \mathbf{W}_b) \text{vec}(\mathbf{H}_b) + \mathbf{n}_b = \mathbf{\Phi} \mathbf{h}_b + \mathbf{n}_b, \quad \mathbf{y}_b = \hat{\mathbf{y}}_b - \mathbf{\Phi} \mathbf{H}_{UA,b} \quad \mathbf{\Phi} = (\mathbf{P}_b \mathbf{s}_b) \otimes \mathbf{W}_b$$
$$\mathbf{h}_b = \text{vec}(\mathbf{H}_b) = \text{vec}(\mathbf{H}_{IA} \mathbf{\Theta} \mathbf{G})$$

$$\mathbf{Y} = \mathbf{\Phi}_{LOS} \mathbf{H}_{LOS} + \mathbf{\Phi}_{NLOS} \mathbf{H}_{NLOS} + \mathbf{N}, \quad (4)$$

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

2. Desenvolvimento

- A vetorização do canal exige muitas estimativas de parâmetros

$$\begin{aligned}\text{vec}(\mathbf{H}_b) &= \text{vec}((\mathbf{F}_{LOS,1}\mathbf{\Gamma}_{LOS}\mathbf{F}_{LOS,2}^H + \mathbf{F}_{NLOS,1}\mathbf{\Gamma}_{NLOS}\mathbf{F}_{NLOS,2}^H)\mathbf{\Theta}\mathbf{R}_1\mathbf{\Lambda}_G\mathbf{R}_2^H) \\ &= \text{vec}(\mathbf{F}_{LOS,1}\mathbf{\Gamma}_{LOS}\mathbf{F}_{LOS,2}^H\mathbf{\Theta}\mathbf{R}_1\mathbf{\Lambda}_G\mathbf{R}_2^H) + \text{vec}(\mathbf{F}_{NLOS,1}\mathbf{\Gamma}_{NLOS}\mathbf{F}_{NLOS,2}^H\mathbf{\Theta}\mathbf{R}_1\mathbf{\Lambda}_G\mathbf{R}_2^H) \\ &\stackrel{(a)}{=} \mathbf{Q}_{LOS}\text{vec}(\mathbf{\Gamma}_{LOS}\mathbf{F}_{LOS,2}^H\mathbf{\Theta}\mathbf{R}_1\mathbf{\Lambda}_G) + \mathbf{Q}_{NLOS}\text{vec}(\mathbf{\Gamma}_{NLOS}\mathbf{F}_{NLOS,2}^H\mathbf{\Theta}\mathbf{R}_1\mathbf{\Lambda}_G) \\ &\stackrel{(b)}{=} \mathbf{Q}_{LOS}(\mathbf{\Lambda}_G^T \otimes \mathbf{\Gamma}_{LOS})(\mathbf{R}_1^H \otimes \mathbf{F}_{LOS,2}^H)v + \mathbf{Q}_{NLOS}(\mathbf{\Lambda}_G^T \otimes \mathbf{\Gamma}_{NLOS})(\mathbf{R}_1^H \otimes \mathbf{F}_{NLOS,2}^H)v \\ &\stackrel{(c)}{=} ((\mathbf{R}_G^H \otimes \mathbf{F}_{LOS,2}^H)v)^T \otimes \mathbf{Q}_{LOS}\mathbf{h}_{LOS,b} + ((\mathbf{R}_G^H \otimes \mathbf{F}_{LOS,2}^H)v)^T \otimes \mathbf{Q}_{NLOS}\mathbf{h}_{NLOS,b}, \quad (5)\end{aligned}$$

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

2. Desenvolvimento

- Solução através da Rede de Aprendizado Profundo baseada em OLNN (Offset Learning Neural Network)

$$\begin{aligned} \min_{\mathbf{H}, \mathbf{U}} \quad & \frac{1}{2} \|\mathbf{Y} - \Phi \mathbf{H}\|_F^2 + \lambda_a g_a(\mathbf{H}_{LOS}) \\ & + \lambda_b g_b(\mathbf{H}_{NLOS}) + \frac{\rho}{2} \|\mathbf{H} - \mathbf{U}\|_F^2 \\ \text{s.t.} \quad & \mathbf{U} = \mathbf{U}_{LOS} + \mathbf{U}_{NLOS}, \quad (6) \end{aligned}$$

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

2. Desenvolvimento

- Projeto do framework da rede e a aprendizagem dos parâmetros, com uma arquitetura composta por quatro módulos.

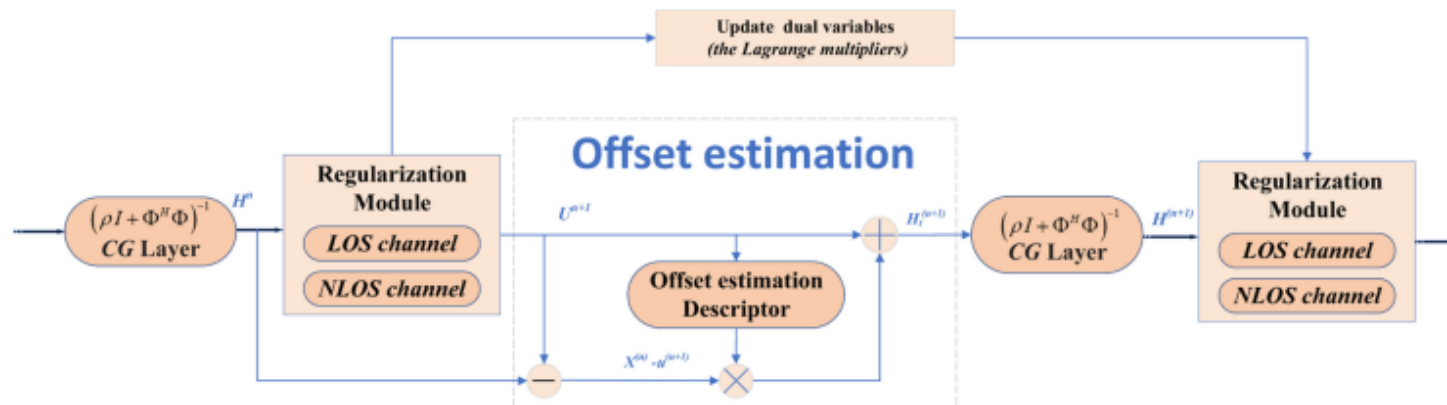


Fig. 3. Overview of the offset learning based indoor channel estimation approach.

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

2. Desenvolvimento

- Projeto do framework da rede e a aprendizagem dos parâmetros, com uma arquitetura composta por quatro módulos.

1. Módulo de otimização CG

$$\mathbf{H}^{(k)} = \left(\rho^{(k)} \mathbf{I} + \Phi^H \Phi \right)^{-1} \left(\rho^{(k)} \mathbf{H}_t^{(k-1)} + \Phi^H \mathbf{Y} \right).$$

2. Modo de regularização $(\hat{\mathbf{Z}}_{LOS}^{(k)})$

$$\mathbf{U}^{(n,k)} = \mu_1^{(n,k)} \mathbf{U}^{(n,k-1)} + \mu_2^{(n,k)} \mathbf{H}^{(n)} - \mathbf{C}_2^{(n,k)},$$

$$\mathbf{C}_1^{(n,k)} = \mathbf{w}_1^{(n,k)} * \mathbf{U}^{(n,k)} + \mathbf{b}_1^{(n,k)}.$$

$$\mathbf{S}^{(n,k)} = \mathcal{S}_{PF} \left(\mathbf{C}_1^{(n,k)}; \left\{ p_i, q_i^{(n,k)} \right\}_{i=1}^{N_c} \right),$$

$$\mathbf{C}_2^{(n,k)} = \mathbf{w}_2^{(n,k)} * \mathbf{S}^{(n,k)} + \mathbf{b}_2^{(n,k)}.$$

3. Modo de regularização $(\mathbf{Z}_{NLOS}^{(k)})$

$$\mathbf{H}_{NLOS}^{(k+1)} = \mathcal{F}(\mathbf{H}, \mathbf{F}, \mathcal{G}, \sigma, \vartheta),$$

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

2. Desenvolvimento

- Projeto do framework da rede e a aprendizagem dos parâmetros, com uma arquitetura composta por quatro módulos.

4. Módulo de estimação em deslocamento

$$\mathbf{H}_t^{(n)} = \mathbf{U}^{(n)} + \mathcal{T}^{(n)} \otimes \left(\mathbf{H}^{(n)} - (\mathbf{H}_{LOS}^{(n)} + \mathbf{H}_{NLOS}^{(n)}) \right)$$

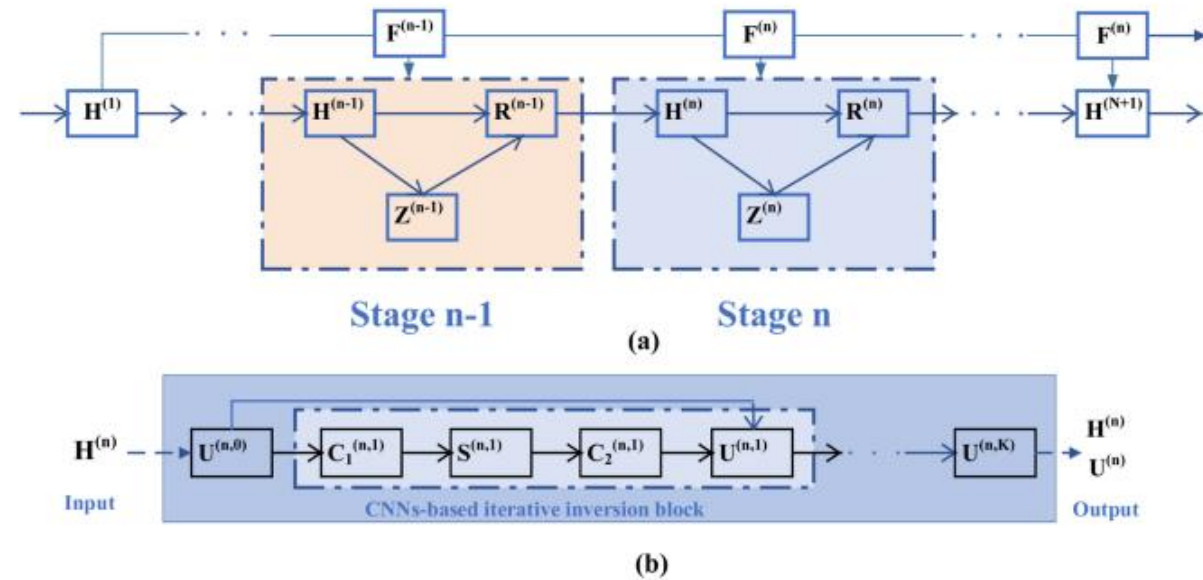


Fig. 4. Framework of the OLNN-Net channel estimation approach.

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication


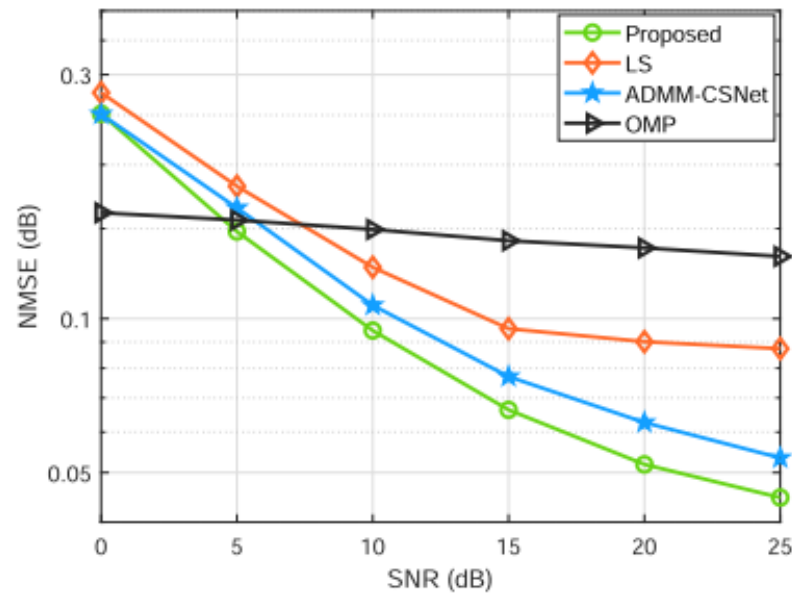
2. Desenvolvimento

- Aprender os parâmetros de cada módulo
- Gerar resultado mais próximo possível do canal verdadeiro
- O objetivo do procedimento de treinamento é aprender o resultado final $\hat{\mathbf{H}}(\mathbf{Y}, \Xi)$ o mais próximo possível do canal verdadeiro \mathbf{H}_0

$$E(\Xi) = \frac{1}{|\psi|} \sum_{(\mathbf{Y}, \mathbf{H}_0) \in \psi} \frac{\sqrt{\|\hat{\mathbf{H}}(\mathbf{Y}, \Xi) - \mathbf{H}_0\|_2^2}}{\sqrt{\|\mathbf{H}_0\|_2^2}}, \quad (7)$$

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

3. Resultados



• A rede neural de aprendizado offset proposta alcançou maior eficiência espectral e menor erro quadrático médio quando comparada a abordagens tradicionais

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

3. Resultados




Fig. 9. (a) ASE performance against the number of clusters at 73 GHz; (b) ASE performance against the number of clusters M at 28 GHz.

- Um pequeno número de clusters não é suficientemente preciso para alcançar um alto ganho do canal baseado em RIS, enquanto um número muito grande de clusters resulta em um processo de estimação de canal computacionalmente caro
- O estimador de canal proposto com frequências de operação a 28 GHz é ligeiramente melhor do que a 73 GHz, com o mesmo número de clusters

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

4. Conclusão

- O estudo conclui que o OLNN-Net proposto é uma abordagem eficiente de estimativa de canal, superando o ADMM-CSNet em termos de NMSE.
- De acordo com análises teóricas e de simulação, o estimador de canal proposto supera os estimadores LS e OMP em um sistema 5G indoor sem conhecimento prévio do canal assistido por RIS e contaminação de pilotos

Offset Learning Based Channel Estimation for Intelligent Reflecting Surface-Assisted Indoor Communication

5. Considerações finais

- Foi utilizado o modelo de canal “MIMO” utilizado na padronização 3GPP
- O estudo considera um ponto de acesso com 36 antenas servindo uma única antena de usuário e ajudado por uma única RIS de 36 elementos refletores
- Duas frequências de operação, 28 e 73 GHz, são utilizadas para verificar a viabilidade do OLNN-Net proposto
- Os resultados da simulação são baseados na média de 20.000 realizações independentes de Monte Carlo